MAESTRÍA EN CIENCIA DE DATOS

UNIVERSIDAD AUSTRAL

ASIGNATURA: INTRODUCCIÓN A LA MINERÍA DE DATOS

REGLAS DE ASOCIACIÓN

OCTUBRE DE 2026

Ejercicio 1: Datos panadería

Se dispone de un conjunto de datos que contiene las transacciones de venta de una panadería, con información sobre los productos adquiridos en cada compra. Se solicita resolver las siguientes consignas:

1) Analizar la distribución de la cantidad de productos por transacción. ¿Cuántos productos se adquieren habitualmente en una compra?

2) Identificar los 10 conjuntos de ítems (*itemsets*) con mayor soporte, considerando:

- ✓ Todos los conjuntos, independientemente de la cantidad de ítems.
- ✓ Únicamente los conjuntos formados por al menos dos ítems.

3) Identificar todos los conjuntos de ítems que incluyan el producto Coffee.

4) Generar reglas de asociación con una **confianza mínima del 60%** y un **soporte absoluto de al menos 25 transacciones**. Ordenar las reglas obtenidas de mayor a menor confianza.

5) Seleccionar, entre las reglas generadas en el punto anterior, aquellas cuyo antecedente incluya el producto Cake, ya sea individualmente o en combinación con otros productos.

6) Representar gráficamente las reglas obtenidas en el punto 4 mediante **tres tipos de visualizaciones diferentes**. Interpretar los resultados e identificar las asociaciones más relevantes.

Ejercicio 2: Características de los hongos

Este conjunto de datos contiene información sobre 8.124 ejemplares de hongos, correspondientes a 23 especies. Cada ejemplar está caracterizado mediante atributos físicos y ambientales, como la forma y el color del sombrero, el olor, las características de las láminas, el tallo y el hábitat.

La variable principal indica si el hongo es comestible (e) o venenoso (p). Es importante destacar que no existe una regla sencilla y universal que permita determinar si un hongo es comestible a partir de su apariencia.

Se solicita resolver las siguientes consignas:

1) Identificar los cinco ítems con mayor soporte.

2) Generar reglas de asociación con un soporte mínimo del 15% y una confianza mínima del 80%, considerando al menos dos ítems por regla. ¿Cuántas reglas se obtienen?

3) Identificar las cinco reglas con mayor *lift*.

4) Generar reglas cuyo consecuente sea exclusivamente {class=p}, utilizando los mismos umbrales del punto anterior. ¿Cuántas reglas se obtienen?

5) Identificar las cinco reglas con mayor *lift*. ¿Qué características aparecen en sus antecedentes?

6) Identificar la regla con mayor soporte entre aquellas que tienen una confianza del 100%. ¿Qué proporción de hongos venenosos permite describir esta regla?

7) Repetir el análisis anterior utilizando {class=e} como consecuente. Identificar las cinco reglas con mayor *lift*.

8) Comparar los resultados obtenidos para hongos comestibles y venenosos. ¿Qué características aparecen con mayor frecuencia en las reglas seleccionadas?

9) Identificar y eliminar las reglas redundantes obtenidas en el punto 4. ¿Cuántas reglas se eliminan? Seleccionar dos reglas redundantes e indicar qué regla más simple permite prescindir de ellas.

10) Representar gráficamente las 15 reglas no redundantes con mayor *lift*, utilizando el método graph. Interpretar las principales asociaciones observadas.

Diccionario de variables

El dataset contiene 22 variables descriptivas categóricas y una variable de clasificación. A continuación, se presentan sus traducciones y categorías:

*class: Clasificación
comestible (e), venenoso (p)
*cap-shape: Forma del sombrero
campana (b), cónico (c), convexo (x), plano (f), con protuberancia (k), hundido (s)
*cap-surface: Superficie del sombrero
Fibrosa (f), con surcos (g), escamosa (y), lisa (s)
*cap-color: Color del sombrero
Marrón (n), beige (b), canela (c), gris (g), verde (r), rosa (p), púrpura (u), rojo (e), blanco (w), amarillo (y)
*bruises: Magulladuras
Presenta magulladuras (t), no presenta (f)
*odor: Olor
Almendra (a), anís (l), creosota (c), pescado (y), desagradable (f), humedad/moho (m), sin olor (n), penetrante (p), especiado (s)
*gill-attachment: Unión de las láminas
Adheridas (a), descendentes (d), libres (f), escotadas (n)
*gill-spacing: Separación de las láminas
Próximas (c), muy juntas (w), distantes (d)
*gill-size: Tamaño de las láminas
Anchas (b), estrechas (n)
gill-color: Color de las láminas
Negro (k), marrón (n), beige (b), chocolate (h), gris (g), verde (r), naranja (o), rosa (p), púrpura (u), rojo (e), blanco (w), amarillo (y)
*stalk-shape: Forma del tallo
Se ensancha (e), se estrecha (t)
*stalk-root: Forma de la base del tallo
Bulbosa (b), en maza (c), en copa (u), uniforme (e), con rizomorfos (z), enraizada (r)
*stalk-surface-above-ring: Superficie del tallo sobre el anillo
Fibrosa (f), escamosa (y), sedosa (k), lisa (s)
*stalk-surface-below-ring: Superficie del tallo debajo del anillo
Fibrosa (f), escamosa (y), sedosa (k), lisa (s)

*stalk-color-above-ring: Color del tallo sobre el anillo
Marrón (n), beige (b), canela (c), gris (g), naranja (o), rosa (p), rojo (e), blanco (w), amarillo (y)
*stalk-color-below-ring: Color del tallo debajo del anillo
Marrón (n), beige (b), canela (c), gris (g), naranja (o), rosa (p), rojo (e), blanco (w), amarillo (y)
*veil-type: Tipo de velo
Parcial (p), universal (u)
*veil-color: Color del velo
Marrón (n), naranja (o), blanco (w), amarillo (y)
*ring-number: Cantidad de anillos
Ninguno (n), uno (o), dos (t)
*ring-type: Tipo de anillo
En forma de telaraña (c), evanescente (e), extendido (f), grande (l), ausente (n), colgante (p), envolvente (s), en zona (z)
*spore-print-color: Color de la impresión de esporas
Negro (k), marrón (n), beige (b), chocolate (h), verde (r), naranja (o), púrpura (u), blanco (w), amarillo (y)
*population: Distribución de los ejemplares
Abundante (a), agrupados (c), numerosos (n), dispersos (s), varios (v), solitarios (y)
*hábitat: Hábitat
Pastizales (g), hojas (l), praderas (m), senderos (p), urbano (u), terrenos baldíos (w), bosques (d)

Ejercicio 3: Películas

Se dispone de un conjunto de datos que contiene información sobre las películas vistas por distintos usuarios. Se solicita resolver las siguientes consignas:

1. **Exploración inicial:** determinar la cantidad de usuarios y de películas diferentes que contiene el dataset.
2. **Conjuntos de ítems frecuentes:** identificar los conjuntos de películas con un soporte mínimo del 10%. ¿Cuáles son las películas más vistas por los usuarios?
3. **Reglas de asociación:** generar reglas con una confianza mínima del 80%. Ordenar las reglas obtenidas de mayor a menor *lift* y seleccionar las 10 primeras.
4. **Visualización:** representar gráficamente las 10 reglas seleccionadas en el punto anterior. Interpretar las principales asociaciones observadas.
5. **Sistema de recomendación:**
   a) se desea recomendar *Forrest Gump* a usuarios que todavía no la vieron. ¿Qué otras películas deberían haber visto estos usuarios para que la recomendación tenga mayor respaldo en las reglas de asociación? Identificar las tres asociaciones más relevantes y justificar la selección.
   b) considerando que *Pulp Fiction* es la película más vista, identificar otras películas que podrían recomendarse a un usuario que ya la vio. Justificar las recomendaciones a partir de las reglas de asociación obtenidas y sus medidas de interés.

Links a los datos:
https://drive.google.com/file/d/13iOSrAY-C-NZqAy9-3YHHeBGmk0Or3Sc/view?usp=drive_link